狗狗评分数据清理项目(wraggling adv dog_rage@twitter)

[TOC]

Understand Project

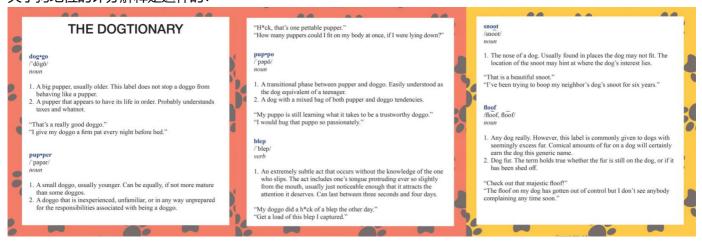
/ background

本项目要整理 (以及分析和可视化) 的数据集是推特用户 @dog_rates 的档案, 推特昵称为 WeRateDogs。 WeRateDogs 是一个推特主,他以诙谐幽默的方式对人们的宠物狗评分。这些评分通常以 10 作为分母。但是分子则一般大于 10: 11/10、12/10、13/10 等等。

WeRateDogs 的推特档案包括 5000 多条推特的基本信息,但并不包括所有内容。不过档案中有一列包含每个推特的文本,我用这一列数据提取了评分、狗的名字和"地位"(即 doggo、floofer、pupper 和 puppo)——这使数据得以"完善"。在这 5000 多条中,我只筛选出了 2356 条包含评分的推特数据。

-	_ rating_ ator denominator	name de	oggo f	floofer	pupper	puppo
10	13 10	Phineas N	lone 1	None	None	None
10	13 10	Tilly N	lone 1	None	None	None
10	12 10	Archie N	lone 1	None	None	None
10	13 10	Darla N	lone 1	None	None	None
10	12 10	Franklin N	lone 1	None	None	None
10	13 10	None N	lone 1	None	None	None
						None
10	13 10	None N	lone I	None	None	None
10	13 10	Zoey N	lone 1	None	None	None
10	14 10	Cassie do	oggo 1	None	None	None
10	13 10	Koda N	lone 1	None	None	None
10	13 10	Bruno N	lone 1	None	None	None
10	13 10	None N	lone 1	None	None	puppo
10	12 10	Ted N	lone 1	None	None	None
10	13 10	Stuart N	lone 1	None	None	puppo
	12	10	10 Ted N	10 Ted None	10 Ted None None	10 Ted None None None

关于狗地位的评分解释是这样的:



- 貌似规则是这样的从年龄上分从年轻到老: pupper < puppo < doggo
- 剩下的3类, blep 为听话、sonnt 为嗅觉好、 floof 为毛多

/ data files

- twitt_json.txt (读入为 df_api) 后收集来的数据,用于修正原始数据(提供了链接)
- twitter-archive-enhanced.txt (读入为 df_arc)原始数据
- image-predictions.tsv (读入为 df_img)图像预测结果 (要求使用 request 库下载, /LINK/)

/ gole

• 对项目数据进行评估

收集上述三个数据集之后,使用目测评估和编程评估的方式,对数据进行质量和清洁度的评估。在你的wrangle_act.ipynb Jupyter Notebook 中记录评估过程和结果,最终列出至少 8 个质量问题 和 2 个清洁度问题。要符合项目规范,必须对项目动机中的要求进行评估(参见上一页课程的 关键要点 标题)。

• 对项目数据进行清洗

对你在评估时列出的每个问题进行清洗。在 wrangle_act.ipynb 展示清洗的过程。结果应该为一个优质干净整洁的主数据集(pandas DataFrame 类型)(如果都是以推特 ID 为观察对象的一些特征列,则清理最终只能有一个主数据集,如果有其他观察对象及其对应的特征字段,可以创建其他的数据集,同样需要清理)。同样地,必须符合项目动机的要点要求。

• 对项目数据进行存储、分析和可视化

将清理后的数据集存储到 CSV 文件中,命名为 twitter_archive_master.csv。如果有其他观察对象的数据集存在,需要多个表格,那么要给这些文件合理命名。另外,你也可以把清洗后的数据存储在 SQLite 数据库中(如果这样存储的话,该数据库文件也需要提交)。

- 在 wrangle_act.ipynb Jupyter Notebook 中对清洗后的数据进行分析和可视化。必须生成至少 3 个见解和 1 个可视化。
- 项目汇报

创建一个 300-600 字的书面报告,命名为 wrangle_report.pdf,在该报告中简要描述你的数据整理过程。这份报告可以看作是一份内部文档,供你的团队成员查看交流。

Solutions

/ data intergration

根据题目的要求,进行了更新(开始跑偏了,直接自己分析的 df_api)

- 主数据 df_arc
 - 主键 twitter_id, 做了一些列的清理
- 附加列 df_img
 - 。 增加狗狗的第1预测分类,确信度和是否狗狗的分类
 - 增加的列 ['p1','p1_conf','p1_dog']
- 附加列 df_api
 - 增加 retweet_count favorite_count 后又觉得 display_text_range 也有价值也增加了
 - 增加的列 ['p1','p1_conf','p1_dog']
- 最终主数据结构:
 - ['tweet_id', 'rating_numerator', 'rating_denominator', 'name', 'doggo',
 'floofer', 'pupper', 'puppo', 'retweet_count', 'favorite_count',
 'display_text_range', 'p1', 'p1_conf', 'p1_dog', 'clean_text']

/ data tidying

// 转换为时序索引

转换为时序索引方便进行时序分析。

// 提取回复长度

display text range 的格式是嵌套的list,从中提取出最大文字,并转换为数值。

// 提取文本

将 text 中后续评分和链接内容排除,提取为新列,并在后续用这些新列做词云的输入。

/ jupyter index

本分析的所有功能为在 jupyter notebook 中完成,附加利用了 wrangeling2.py 作为常用分析函数。并且在词云生成时需要使用 t1, t2 两个图片文件。

jupyter notebook 使用 toc 生成目录的话会比较方便浏览,其中展开的部分为项目涉及部分:

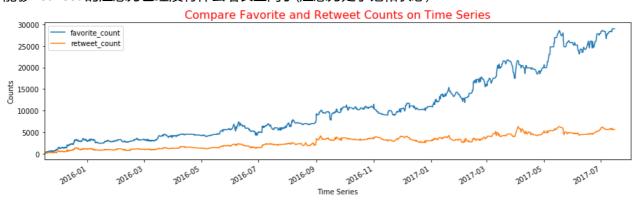
Contents 2 *

- ▼1 收集
 - 1.1 / import lib
 - 1.2 / display setting
 - 1.3 / load df
- ▶ 2 评估 twitt json
- ▶ 3 评估 twitter-archive-enhanced
- ▶ 4 评估 image-predictions
- ▼ 5 评估 总结
 - 5.1 / load df (inspect)
 - 5.2 / merge df
 - 5.3 / persistence
- ▼ 6 清理 (Tidiness)
 - 6.1 / load df
 - 6.2 / created_at
 - 6.3 / display_text_range
 - 6.4 / full_text
 - 6.5 / data type
 - 6.6 / check null
 - 6.7 / check duplicated
 - 6.8 / check outlier
 - 6.9 / persistence
- ▶ 7 探索 (非项目要求)
- ▶ 8 结论 (非项目要求)

Conclution

/ favorite 和 retweet 时序分析

- 2016年上半年之前, favorite 数量大概是 retweet 的两倍
- 但再这之后, favorite 数量大量上涨, retweet 数量上涨十分缓慢(两者之比达到6倍)
- 推测相关因素如下:
 - 。 可以看出 twitter 增长非常迅速(可惜缺少用户量相关的数据)
 - 但是人们愿意付出更多一点时间 retweet 的时间在减少,可能原因是当人接触到更多的 twitter 信息后, 能够 retweet 的注意力已经没有什么增长空间了(注意力处于饱和状态)



/ word cloud 分析

- 对评论使用 word cloud 进行分析
- 去掉了 stop words
- 图像为 twitter 英文字符(小鸟图不太美观)





/ text range 分析

- text range 改名为 text range 更为明确
- 数据做了过滤(过滤掉了个别 160 字符的)
- 数据有左偏斜趋势 (不能断定) 因为在140字的限制上有大量出现, 所以明显存在人为调整
- 有些数据超出了140

• 后续可以做异常值分析(按说不应该有超出,也可能是正则化过滤时留下的问题)

